

Trabalhos Práticos de Algoritmos e Estruturas de Dados III

Ludmila B. S. Nascimento, Marcos A. C. V. Silva

¹Pontifícia Universidade Católica de Minas Gerais, Brasil

ludmila.bruna@sga.pucminas.br, curymarcos@live.com

Abstract. *The objective of this work was to develop an application using the GoogLeNet algorithm for automatic recognition of breast density in mammographic images. The application is capable of reading the images, segmenting the breast area from the background, and applying the GoogLeNet model to identify breast density. The test results showed that, for binary classification, there was no significant difference in performance between the original and segmented images. However, in multi-class classification, the original images performed slightly better. The execution time was slightly longer for segmented images. These findings provide insights for the development of an automated and accurate application for evaluating the risk of breast cancer development. As future work, it is suggested to explore advanced pre-processing techniques, conduct studies on larger databases, and investigate other parameters for the use of the GoogLeNet algorithm.*

Resumo. *Este trabalho teve como objetivo desenvolver um aplicativo utilizando o algoritmo GoogLeNet para o reconhecimento automático da densidade mamária em imagens de exames mamográficos. O aplicativo é capaz de ler as imagens, segmentar a área da mama do fundo e aplicar o modelo GoogLeNet para identificar a densidade mamária. Os resultados dos testes mostraram que, para a classificação binária, não houve diferença significativa de desempenho entre as imagens originais e segmentadas. Já na classificação multi classe, as imagens originais tiveram um desempenho ligeiramente melhor. O tempo de execução foi um pouco maior para as imagens segmentadas. Essas conclusões fornecem insights para o desenvolvimento de um aplicativo automatizado e preciso na avaliação do risco de desenvolvimento de câncer de mama. Como trabalhos futuros, sugere-se explorar técnicas de pré-processamento avançadas, realizar estudos em bases de dados maiores e explorar outros parâmetros para o uso do algoritmo GoogLeNet.*

1. Introdução

O câncer de mama é o tipo mais comum de câncer em mulheres em todo o mundo, representando cerca de 24,5% dos casos. No Brasil, foram estimados 66.280 novos casos em 2021, com uma taxa de mortalidade ajustada por idade de 14,23/100 mil em 2019. Os principais sinais incluem caroço na mama, pele avermelhada, alterações no mamilo e presença de nódulos nas axilas ou pescoço [Instituto Nacional de Câncer (INCA) 2023].

Uma das formas de detectar o cancer de mama é através de exames de imagens. O BIRADS (Breast Imaging Reporting and Data System) é um sistema desenvolvido pelo

American College of Radiology para padronizar a interpretação e relato de exames de imagem da mama. Ele classifica lesões em uma escala: I (quase inteiramente composta por gordura), II (tecido fibroglandular difuso), III (tecido denso heterogêneo) e IV (tecido extremamente denso), ajudando a guiar a conduta médica. O BIRADS melhora a precisão e consistência dos relatórios, facilitando o diagnóstico e tratamento do câncer de mama [Balleyguier et al. 2007].

As redes neurais, incluindo o GoogLeNet, são amplamente usadas na detecção de câncer devido à sua capacidade de aprender padrões complexos e extrair características relevantes dos dados. O GoogLeNet, em particular, é uma arquitetura profunda de rede neural convolucional projetada para tarefas de visão computacional, como a detecção de câncer. Sua eficiência computacional e desempenho impressionante tornam-no uma escolha promissora para auxiliar no diagnóstico preciso e precoce do câncer por meio da análise de imagens médicas [AL-Huseiny and Sajit 2021].

O objetivo deste trabalho é desenvolver um aplicativo que utilize o GoogLeNet para realizar o reconhecimento automático da densidade mamária em imagens de exames mamográficos. O aplicativo será capaz de ler as imagens, segmentar a área da mama do fundo e aplicar o modelo GoogLeNet para identificar a densidade mamária. Isso permitirá uma análise automatizada e precisa da densidade mamária, o que é importante para avaliar o risco de desenvolvimento de câncer de mama.

O restante deste texto segue a seguinte estrutura: a Seção 2 traz o referencial, contendo as técnicas normalmente utilizadas para conversão de atributos nominais. A Seção 3 apresenta a metodologia adotada neste estudo. A Seção 4 explora os resultados alcançados durante os experimentos. Por último, a Seção 5 traz as considerações finais e aponta para trabalhos futuros.

2. Referencial Teórico

2.1. Segmentação Limiar

A segmentação de imagens é uma etapa crucial no processamento de imagens digitais, pois define a base para todo o trabalho subsequente. Existem diversas técnicas utilizadas na segmentação de imagens, e cada uma delas é selecionada de acordo com o problema a ser resolvido. Não há um modelo formal único para o processo de segmentação, pois ele deve ser adaptado de acordo com o tipo de imagem em estudo [Albuquerque et al. 2007].

Uma abordagem comum na segmentação por região é a técnica de segmentação por limiar (thresholding). Nessa técnica, um valor de cinza é escolhido como limiar, e os tons de cinza acima desse valor são considerados parte do objeto, enquanto os tons de cinza abaixo são considerados parte do fundo. Essa abordagem permite separar a imagem em regiões com base no valor de intensidade dos pixels [Moreira et al. 2002].

2.1.1. Abordagem de Otsu

A segmentação baseada em limiar adaptativo de Otsu é um algoritmo que utiliza o histograma de uma imagem para determinar um limiar global. Esse limiar é aplicado para separar os pixels da imagem em duas classes, geralmente objetos de interesse e fundo [Dias et al. 2016]. O método de Otsu é utilizado para determinar o valor ideal de limiar

que permite separar os elementos do fundo e da frente da imagem em dois grupos distintos. Cada grupo é então atribuído à cor branca ou preta, respectivamente [Otsu 1979]. Após encontrar o limiar ideal, a imagem original é sobreposta à imagem resultante do método de Otsu, gerando uma nova imagem combinada [Carvalho et al.].

2.2. GoogLeNet

O GoogLeNet é uma rede neural convolucional com arquitetura avançada, projetada para lidar com representações de alta qualidade em imagens. Ele utiliza milhões de imagens do conjunto de dados ImageNet para classificar padrões em cerca de 1000 categorias diferentes. Comparado ao AlexNet, o GoogLeNet usa significativamente menos parâmetros. Sua arquitetura inclui 22 camadas, com destaque para os 9 módulos de inception, que utilizam filtros aprendíveis de diferentes tamanhos para capturar características detalhadas. O modelo aceita imagens como entrada e produz rótulos de classe junto com a confiança associada a cada previsão [AL-Huseiny and Sajit 2021].

3. Materiais e Métodos

Neste trabalho, utilizamos uma base de dados contendo um total de 5024 imagens de mamas. Dessas imagens, 1256 foram reservadas para teste, enquanto as demais foram destinadas ao treinamento do modelo. As imagens foram classificadas em quatro categorias distintas: BIRADS I, II, III e IV. Além disso, a base de dados inclui imagens de mamas direitas e esquerdas, capturadas nas orientações crânio-caudal e médio-lateral.

É importante destacar que a base de dados foi balanceada, o que significa que todas as classes possuíam uma quantidade similar de amostras, garantindo uma representação equilibrada dos diferentes tipos de casos.

Para todos os algoritmos implementados foi utilizada a linguagem Python, versão 3.10.9. Além disso foram utilizadas as bibliotecas Tkinter ¹ para a interface gráfica, Tensorflow ² e Sklearn ³ para GoogLeNet e Numpy ⁴, CV2 ⁵, PIL ⁶ e OS ⁷ para os demais códigos.

3.1. Pré Processamento

O pré processamento é crucial na área de aprendizado de máquina. Quando se trata de imagens ele envolve etapas que melhoram a qualidade dos dados e permitem que o algoritmo de classificação aprenda padrões precisos para tomar decisões mais acuradas. Para este estudo, aplicamos o pré processamento de imagens na seguinte ordem: Segmentação com Gaussiano e limiar de Otsu, a segmentação de imagens pode ser facilitada usando técnicas como a filtragem Gaussiana para suavizar a imagem e reduzir o ruído, bem como o limiar de Otsu para encontrar um valor de limiar ideal para binarizar a imagem. Essas técnicas ajudam a identificar e separar objetos ou regiões de interesse.

¹ Documentação oficial disponível em: Tkinter

² Documentação oficial disponível em: Tensorflow

³ Documentação oficial disponível em: Sklearn

⁴ Documentação oficial disponível em: Numpy

⁵ Documentação oficial disponível em: CV2

⁶ Documentação oficial disponível em: PIL

⁷ Documentação oficial disponível em: OS

Máscara, a máscara em processamento de imagem é uma região de interesse que pode ser aplicada à imagem original para isolar ou destacar uma parte específica. Ela é uma matriz binária com valores 0 ou 1, onde 0 representa pixels fora da região de interesse e 1 representa pixels dentro da região de interesse. A máscara permite operações seletivas em áreas específicas da imagem.

Bitwise, operações bitwise são operações que manipulam os bits individuais de um valor binário. Essas operações são executadas bit a bit sendo úteis para manipular e extrair informações específicas dos bits de um valor.

Em seguida, aplica-se a segmentação novamente: a limiarização é aplicada para transformar a imagem em uma representação binária. Em seguida, os contornos são identificados na imagem binarizada. Contornos menores que um valor pré-determinado são removidos. Uma máscara é criada com os contornos mantidos e, em seguida, é aplicada uma operação bitwise entre a máscara e a imagem original para remover os itens menores. Esse processo ajuda a destacar os objetos de interesse e eliminar ruídos.

3.2. Algoritmo de Treinamento

Para realizar a classificação neste trabalho, utilizamos a arquitetura da rede convolucional GoogLeNet. Foram realizados dois testes distintos:

- Classificação binária: Neste teste, agrupamos as classes BIRADS I e II como uma única classe e as classes BIRADS III e IV como outra classe. O objetivo era classificar as imagens em dois grupos distintos, com base nessas duas categorias.
- Classificação multi classe: Neste teste, utilizamos todas as quatro classes BIRADS (I, II, III e IV). O objetivo era realizar a classificação das imagens em quatro grupos distintos, cada um representando uma categoria BIRADS específica.

Em ambos os tipos de classificação, tanto na binária quanto na multi classe, foram utilizadas as imagens originais e também as imagens segmentadas. A inclusão das imagens segmentadas permitiu explorar informações mais detalhadas e específicas das regiões de interesse nas mamas. Além disso, para evitar o overfitting, foi alterado o parâmetro de épocas (5) durante o treinamento. O ajuste desse parâmetro contribuiu para regularizar o modelo e impedir que ele memorize demais os dados de treinamento, melhorando assim sua capacidade de generalização para dados não vistos anteriormente.

4. Resultados e Discussões

Após a análise dos resultados dos testes realizados com o algoritmo GoogLeNet e as diferentes abordagens de imagem (original e segmentada), podemos destacar os seguintes resultados:

Classificação binária: Não houve diferença significativa de desempenho entre as imagens originais e segmentadas. Ambas as abordagens apresentaram resultados idênticos em termos de recall (0.5), precisão (0.25) e acurácia (0.5). Isso indica que a segmentação das imagens não teve impacto significativo na capacidade do modelo em realizar a classificação binária.

Classificação multi classe: As imagens originais apresentaram um desempenho ligeiramente superior em relação às imagens segmentadas. Os valores de recall (0.24 original e 0.26 segmentada), precisão (0.24 original e 0.26 segmentada) e acurácia (0.66

original e 0.64 segmentada) foram um pouco melhores para as imagens originais. Isso sugere que as informações contidas nas imagens originais foram mais relevantes para a classificação multi classe em comparação com as imagens segmentadas.

Tempo de execução: Houve diferenças no tempo de execução entre as abordagens de imagem. No geral, o processamento das imagens segmentadas levou mais tempo do que o das imagens originais em ambas as classificações. No entanto, as diferenças de tempo foram relativamente pequenas.

Em resumo, os resultados indicam que, para a classificação binária, as imagens originais e segmentadas foram igualmente eficazes. Já para a classificação multi classe, as imagens originais apresentaram um desempenho um pouco melhor. Considerando também o tempo de execução, pode-se concluir que as imagens originais podem ser uma opção mais eficiente em termos de desempenho e tempo de processamento levando em consideração os parâmetros escolhidos.

5. Conclusão

Após a análise dos resultados dos testes com o algoritmo GoogLeNet e as diferentes abordagens de imagem, concluímos que:

- Para a classificação binária, as imagens originais e segmentadas tiveram desempenho equivalente, sem diferenças significativas nos resultados.
- Na classificação multi classe, as imagens originais apresentaram um desempenho ligeiramente superior em relação às imagens segmentadas, com valores um pouco melhores de recall, precisão e acurácia.
- O tempo de execução foi ligeiramente maior para as imagens segmentadas em ambas as classificações, embora as diferenças tenham sido pequenas.

Em resumo, as imagens originais mostraram-se eficazes para a classificação binária e multi classe, com um desempenho ligeiramente melhor do que as imagens segmentadas. Considerando também o tempo de execução, as imagens originais são uma opção mais eficiente. Essas conclusões são relevantes para o desenvolvimento do aplicativo de reconhecimento automático da densidade mamária, proporcionando uma análise automatizada e precisa para avaliar o risco de desenvolvimento de câncer de mama.

Existem algumas direções interessantes para trabalhos futuros relacionados ao reconhecimento automático da densidade mamária usando o algoritmo GoogLeNet. Alguns possíveis caminhos a serem explorados incluem: utilizar técnicas de pré-processamento avançadas, realizar estudos em bases de dados maiores, explorar outros parâmetros para o uso do algoritmo GoogLeNet.

Referências

- [AL-Huseiny and Sajit 2021] AL-Huseiny, M. S. and Sajit, A. S. (2021). Transfer learning with googlenet for detection of lung cancer. *Indonesian Journal of Electrical Engineering and Computer Science*, 22(2):1078–1086.
- [Albuquerque et al. 2007] Albuquerque, V. H. C. d., Cortez, P. C., Alexandria, A. R. d., Aguiar, W. M., and Silva, E. d. M. (2007). Sistema de segmentação de imagens para quantificação de microestruturas em metais utilizando redes neurais artificiais. *Matéria (Rio de Janeiro)*, 12:394–407.

- [Balleyguier et al. 2007] Balleyguier, C., Ayadi, S., Van Nguyen, K., Vanel, D., Dromain, C., and Sigal, R. (2007). Birads™ classification in mammography. *European Journal of Radiology*, 61(2):192–194. Breast Imaging: The BIRADS of the ACR.
- [Carvalho et al.] Carvalho, E., Ferreira, M. V., Leal, R., and Silva, F. A. Análise de desempenho de um sistema distribuído para segmentação de imagens da retina.
- [Dias et al. 2016] Dias, L. O., De Bom, C. R., Guimaraes, H., Faria, E. L., de Albuquerque, M. P., de Albuquerque, M. P., Correia, M. D., and Surmas, R. (2016). Segmentação textural de imagens de rocha por microtomografia segmentation of microtomography images of rocks using texture filter. *Notas Técnicas*, 6(1).
- [Instituto Nacional de Câncer (INCA) 2023] Instituto Nacional de Câncer (INCA) (2023). Outubro Rosa 2022. <https://www.inca.gov.br/numeros-de-cancer>. Acesso em: 10 de junho de 2023.
- [Moreira et al. 2002] Moreira, F. C. et al. (2002). Reconhecimento e classificação de padrões de imagens de núcleos de linfócitos do sangue periférico humano com a utilização de redes neurais artificiais.
- [Otsu 1979] Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62–66.